2026. 10. 21 · 최종 과제 보고서

Day Zero
토론으로 인성을 본다

AI 동료 3명과의 채팅 토론에서 인성을 관찰하는 채용 서비스

서비스 구성	web · api · MCP 3 · worker
아키텍처 원본	docs/share/architecture.html

목차

1 **서비스 개요** 3

1.1 핵심 요약 3

1.2 문제 정의와 서비스 구성 4

2 **시스템 아키텍처** 5

2.1 전체 구성 5

2.2 구성 요소와 배포 6

3 **에이전트 설계** 7

3.1 에이전트 구성 7

3.2 토론 턴 흐름 8

3.3 단계 전환과 칸 확정 9

4 **MCP 설계와 접근 경계** 10

5 **평가 설계(BARS)** 11

6 **품질 관리와 하네스** 12

7 **주요 기능과 구현 결과** 13

7.1 지원자 화면 13

7.2 디브리핑과 관리자 리포트 14

8 **한계와 개선 방향** 15

1.1 핵심 요약

60분 토론 한 번으로 인성 5요소의 행동 근거를 남긴다.

지원자가 AI 동료 3명과 키워드 · 문제 상황 · 해결책을 정하고 기획안을 내면,
평가 에이전트가 근거를 들어 수준을 제안하고 담당자가 최종 평가합니다.

세션
60분
단계별 10 · 18 · 18 · 14분, 데모 15분

진행 단계
4단계
키워드 → 문제 상황 → 해결책 → 기획안

AI 동료
3명
강한결 · 윤하람 · 서지안, 모든 세션 고정

인성 요소
5요소
설득 · 경청 · 배려 · 수용 · 정직

BARS 척도
19차원
차원마다 수준 1~5 + 근거

MCP 서버
3개
debate · rag · assessment, 도구 16개

표 1-1 **핵심 설계 결정**

결정	내용
결정은 코드, 말투는 LLM	입장 · 합의 · 카드 시각 · 시간 초과는 규칙이 정하고, LLM은 화자 보조와 발언 문장만 만든다
세션별 메일박스	자극 4종을 Task 하나가 차례로 처리한다. 새 지원자 메시지가 오면 남은 화자는 버린다
시간과 쓰기의 주인은 api	시간 초과 채우기와 업무 데이터 쓰기는 api만 한다 (체크포인트 · 색인은 예외). MCP와 워커는 `/internal`을 부른다
평가 정보 차단	페르소나는 assessment-mcp에 닿지 않는다(허용 목록 + 토큰)

핵심 메시지

(1)
장면은 같고 말투만 다르다
같은 채용 건의 지원자는 같은 페르소나 · 카드 6장 · 시간 규칙을 겪습니다.

(2)
AI 동료는 평가 기준을 모른다
토론에 참여하는 페르소나는 척도와 관찰 기록에 접근할 수 없습니다.

(3)
판단은 근거로, 확정은 사람이
근거 없는 수준은 내지 않고, 담당자가 차원 단위로 조정합니다. 총점은 없습니다.

1.2 문제 정의와 서비스 구성

말로 묻는 검사 대신 토론 속 행동을 근거로 쓴다.

기업은 인성과 협업 태도를 중요하게 보지만 측정은 자기 보고와 짧은 면접에 기댑니다.
Day Zero는 그 태도가 드러나는 상황을 토론으로 만들고 발언을 근거로 남깁니다.

표 1–2 **문제와 근거**

문제	근거
원하는 것과 재는 것이 다르다	면접 유형은 질의응답이 94.1%, 실무 수행은 10.7%
자기 보고는 꾸밀 수 있다	거짓말이 가장 잘 드러나는 전형으로 실무면접 65.5%, 인적성 검사 2.4%
잘못된 채용은 비싸다	인사담당자 60.9%가 최근 1년 안에 신입 조기 퇴사를 경험
지원자는 이유를 모른다	취업준비생 51.5%가 최종 면접 불합격 통보조차 받지 못함

표 1–3 **60분 세션 흐름**

단계	시간	장면	관찰 요소
키워드	10분	후보 4개(물 · 불 · 나무 · 바람) 중 하나로 합의. 다른 키워드를 민 동료가 반론	설득
문제 상황	18분	두 동료가 지원자 안과 다른 안을 지지하고 고집형 동료가 강하게 밈	수용 · 경청
해결책	18분	소극형 동료가 말을 거두고, 비판형 동료가 지원자 안의 약점을 자료로 짚음	배려 · 설득
기획안	14분	지원자가 6칸 템플릿을 혼자 써서 제출. 아이디어 기여 칸을 실제 최초 제안자와 대조	정직

기업이 받는 것

토론 기록 · 제출 기획안과 함께, 차원별 수준과 근거, 확신도가 담긴 리포트. 합격 · 불합격 · 순위는 만들지 않습니다.

지원자가 받는 것

말이 아닌 행동으로 보여 줄 기회와 디브리핑. 어떤 장면이 설계되어 있었는지 설명하고 이의 제기 경로를 줍니다.

2.1 전체 구성

브라우저는 api만 만나고, 에이전트는 MCP 세 개를 도구로 쓴다.

번호는 지원자 메시지 한 번과 세션 종료 뒤 리포트까지의 처리 순서입니다.
빨간 화살표는 아래 계층이 api의 `/internal`을 부르는 예외 호출입니다.

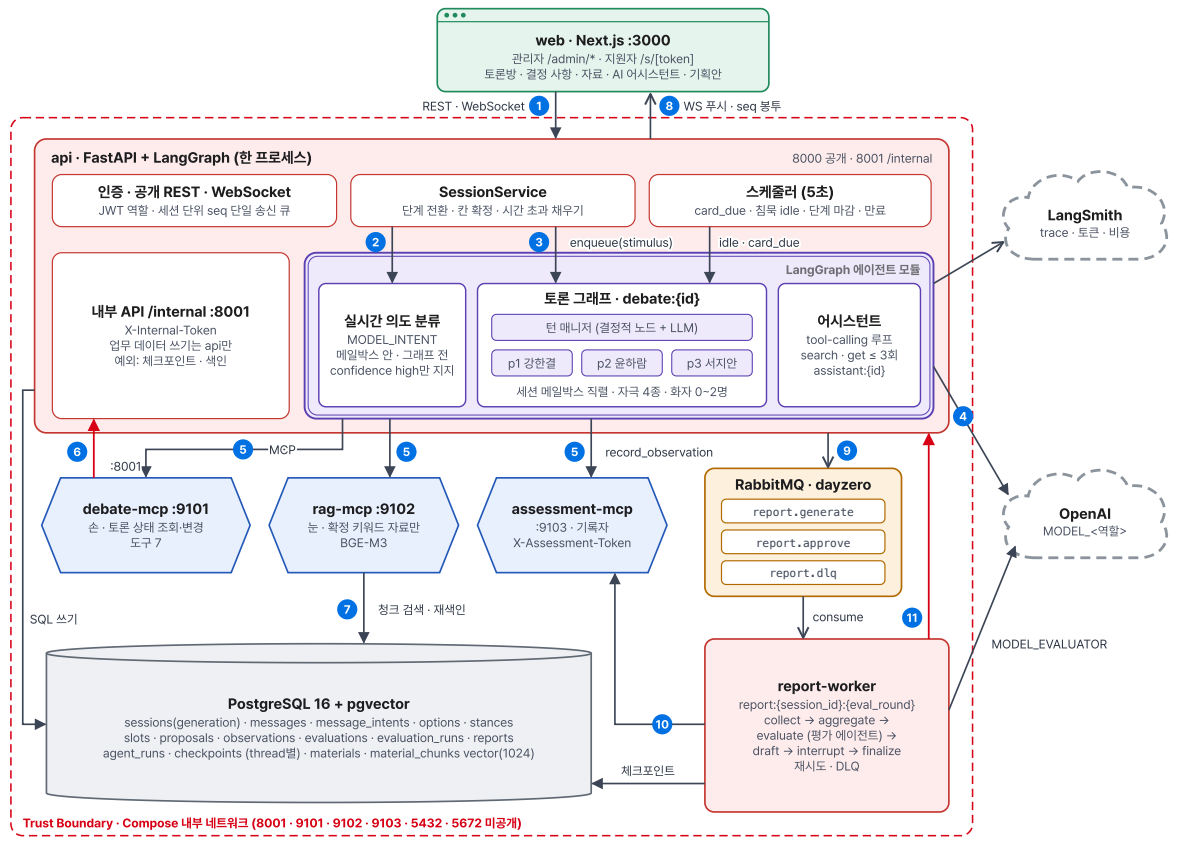


그림 2–1 전체 구성도. 공개 포트는 web과 api뿐이고, MCP · 워커 · DB · 큐는 Compose 내부 네트워크에 있습니다.

표 2–1 번호별 처리 흐름

번호	구간	처리 내용	프로토콜
1	web → api	지원자 메시지와 화면 REST(확정 · 저장 · 제출)	WebSocket, REST
2·3	api → 의도 분류 · 그래프	큐 밖에서는 저장 · generation +1 · message.ack(분류 전)만. 메일박스가 자극을 꺼내면 분류해 지지(참여자당 하나)를 반영한 뒤 그래프 실행	프로세스 내부
4·5	에이전트 → OpenAI · MCP	역할별 모델 호출, 허용된 MCP 도구 호출	HTTPS, MCP HTTP
6·7	MCP → api · pgvector	변경 · 자료 원문은 `/internal` 경유, 청크 검색만 pgvector 직접	HTTP :8001, SQL
8	api → web	발언 · 입력 중 · 칸 확정 · 단계 전환을 seq 봉투로 푸시	WebSocket
9~11	api → 큐 → 워커	종료 뒤 리포트 작업 발행, 평가 저장, 리포트 저장. thread는 `report:{session_id}:{eval_round}`	AMQP, MCP, HTTP

2.2 구성 요소와 배포

서비스는 8개이고, 업무 데이터는 api만 쓴다.

구성 요소마다 맡은 일과 하지 않는 일을 정해 경계를 지킵니다. 에이전트는 api 프로세스 안의 모듈이지만 계층은 라우터 → SessionService → AgentRunner → 그래프 → MCP 어댑터로 나눕니다.

표 2-2 **구성 요소별 역할과 금지 사항**

구성 요소	역할	하지 않는 일
web	지원자 토론 화면과 관리자 리포트 화면	권한 판단, MCP 직접 호출
api	인증 · REST · WebSocket, 단계 전환과 칸 확정, 시간 초과 채우기, 스케줄러, 업무 데이터 쓰기	—
에이전트 모듈	의도 분류 · 토론 그래프 · 어시스턴트(api 안)	DB 직접 쓰기
debate-mcp	토론 상태 조회 · 발언 게시 · 안 제안 · 입장 · 칸 채우기	토론 규칙 판단(api가 최종)
rag-mcp	확정 키워드 청크 검색 · 재색인(직접), 원문 조회(`/internal` 경유)	에이전트에 변경 도구 노출
assessment-mcp	카드 관찰 기록 · 평가 입력 조회 · 평가 저장	페르소나의 접근 허용
report-worker	리포트 그래프와 평가 에이전트, 재시도와 DLQ. 직접 쓰기는 체크포인트만	수준 · 근거 고쳐 쓰기

표 2-3 **Compose 서비스와 포트**

서비스	포트	기다리는 의존 · 비고
web	`3000` 공개	api
api	`8000` 공개 · `8001`	postgres · rabbitmq · MCP 3개. 8001은 내부 전용
debate-mcp	`9101`	FastMCP
rag-mcp	`9102`	postgres. BGE-M3, 메모리 3GB
assessment-mcp	`9103`	FastMCP, 토큰 검사
report-worker	없음	postgres · rabbitmq · api · assessment-mcp. heartbeat 30초
postgres	`5432`	PostgreSQL 16 + pgvector
rabbitmq	`5672`	관리 UI는 127.0.0.1에만

3.1 에이전트 구성

참여자로 보이는 AI는 셋, 뒤에서 일하는 에이전트는 넷이다.

세션 중에는 api 안에서 의도 분류 · 토론 그래프 · 어시스턴트가 돌고, 세션이 끝나면 report-worker의 평가 에이전트가 돕니다.

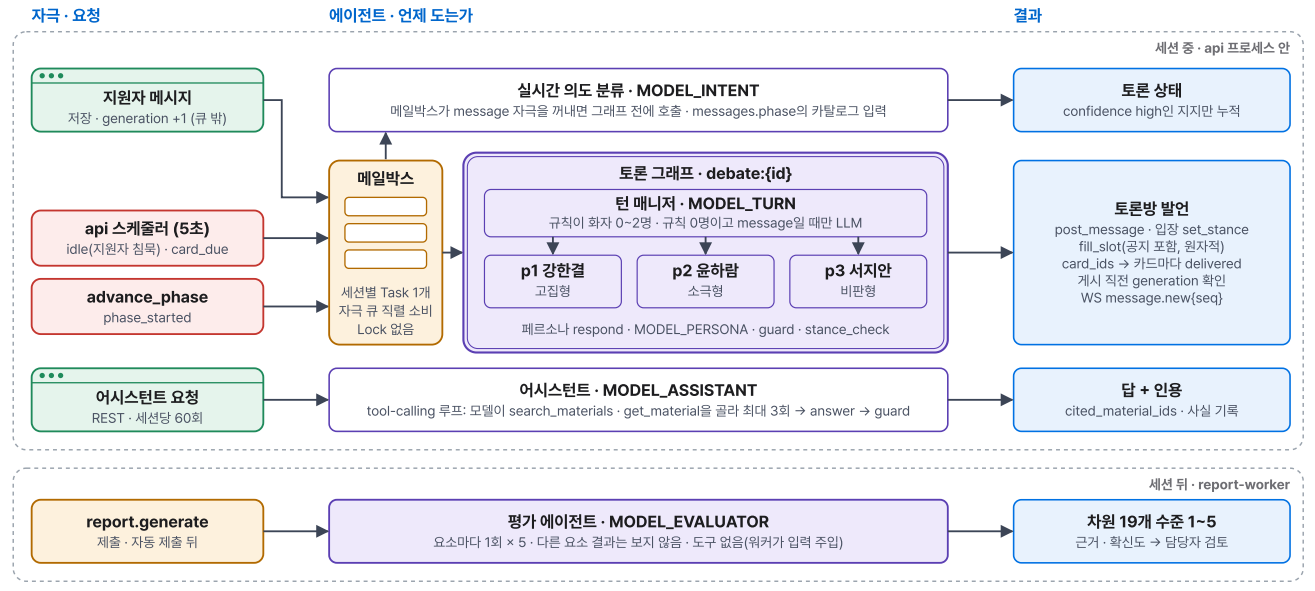


그림 3–1 에이전트 구성도. 자극은 메일박스로 모여 토론 그래프가 하나씩 처리하고, 평가는 세션 뒤 큐 작업으로 분리됩니다.

표 3–1 에이전트별 역할

에이전트	하는 일	도구
턴 매니저	자극마다 화자 0~2명을 규칙으로 정하고, 결과가 0명인 메시지에만 LLM을 씀	결정적 노드가 debate-mcp 전부 · record_observation
페르소나 × 3	성향 · 고정 입장 · 자리 기억으로 1~3문장 발언	get_transcript · get_draft · rag 2, 응답당 3회. DebateState는 컨텍스트로
의도 분류	지원자 메시지를 저장된 단계(messages.phase) 기준으로 제안 · 동의 · 반대 · 질문 · 기타와 대상 안으로 분류	없음, 10초 넘으면 기타
어시스턴트	지원자 요청에 자료를 스스로 골라 인용과 함께 답함	rag 2, 최대 3회
평가 에이전트	요소마다 1회 호출로 차원별 수준 · 근거 · 확신도 판단	없음(워커가 입력 주입)

표 3–2 세션 페르소나

자리	이름 · 유형	토론에서 하는 일
p1	**강한결 · 고집형**	자기 안을 반복해 밀고 반대에 바로 재반박. 확정 전에는 입장을 바꾸지 않음. 서지안이 못 맡는 설득 카드를 대신 맡음
p2	**윤하람 · 소극형**	스스로 주장하지 않음. 이름이 불리면 자료 근거로 자기 안을 말함
p3	**서지안 · 비판형**	모이는 안의 약점을 짚음. 지원자의 반대 · 대안 2회면 설득됨. 설득 카드 우선 담당(지원자가 서지안 안을 지지하면 강한결)

3.2 토론 턴 흐름

메시지 한 번은 분류, 화자 선택, 발언, 검사를 거쳐 게시된다.

토큰 스트리밍 없이 guard를 통과한 완성 문장만 게시합니다. 결과는 WebSocket으로, 저장은 MCP를 거쳐 api가 합니다.

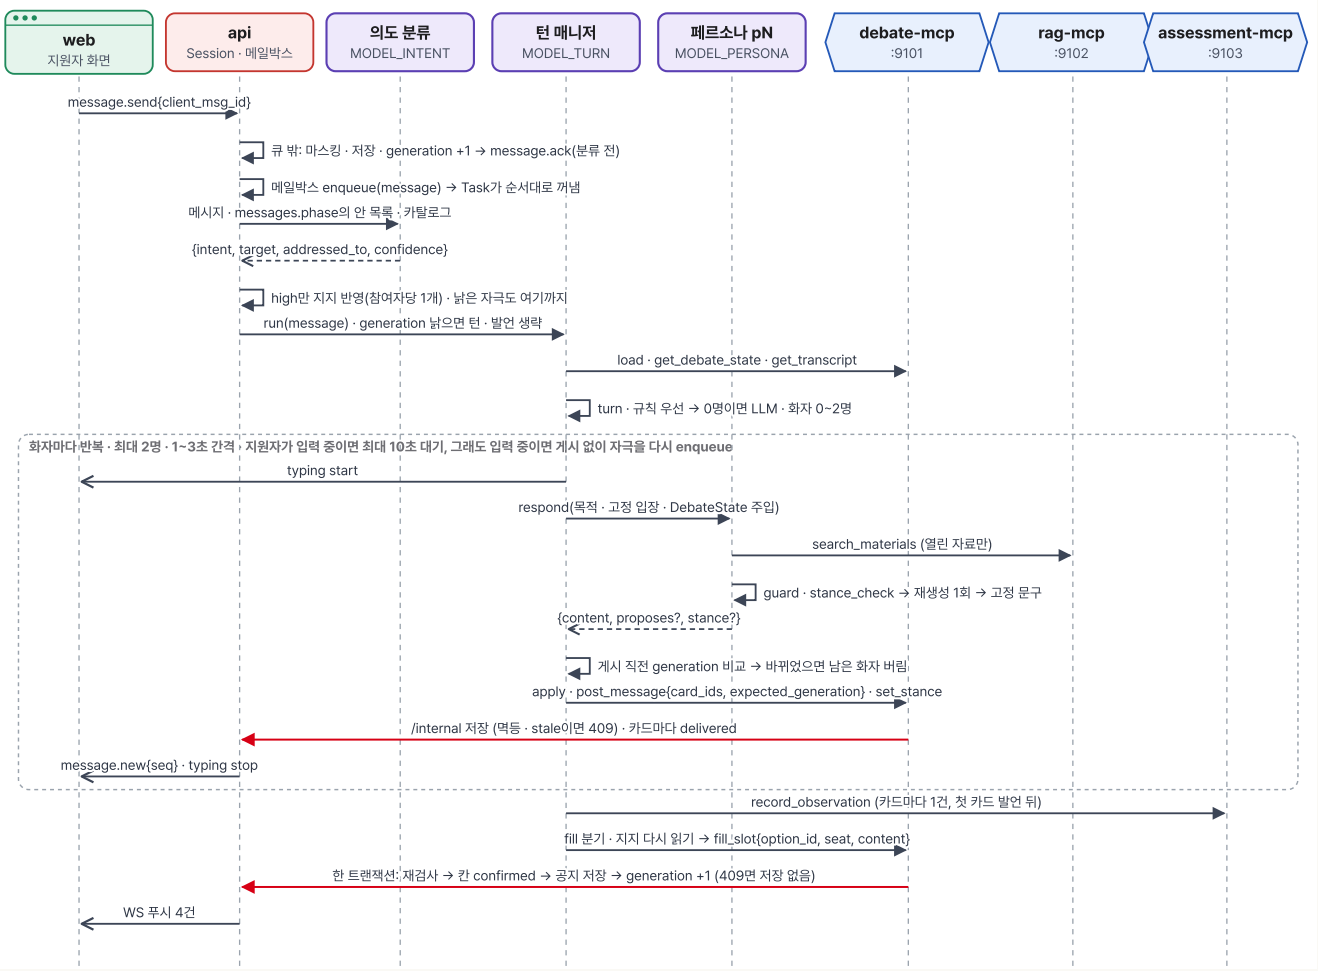


그림 3–2 토론 한 턴 시퀀스. 화자마다 respond → guard → stance_check → apply를 반복하고, 게시 직전에 새 메시지가 왔는지 확인합니다.

표 3–3 토론 턴 규칙

규칙	처리
끼어들기	지원자 메시지를 저장하면 generation이 +1 됩니다. 그래프는 게시 직전에 값이 바뀐 것을 보고 남은 화자를 버립니다
입력 중 표시	클라이언트는 5초마다 typing을 갱신하고 서버는 6초 동안 갱신이 없으면 만료합니다
검사	guard는 점수 · 판정 · 결론 대리 · 미래 카드 암시를 막고, stance_check는 계획 밖 입장을 막습니다. 각각 재생성 1회 뒤 고정 문구
실패	발언 실패는 그 발언만 생략(연속 3회면 세션 실패), turn LLM 실패는 규칙 결과만, MCP 장애는 1회 재시도

3.3 단계 전환과 칸 확정

단계 시간과 칸 확정은 규칙이 정하고 LLM은 문장만 만든다.

칸 상태는 `empty`와 `confirmed` 두 개이고, 확정 경로에는 LLM이 없습니다. 칸마다 합의 · 시간 초과와 채운 사람을 남깁니다.

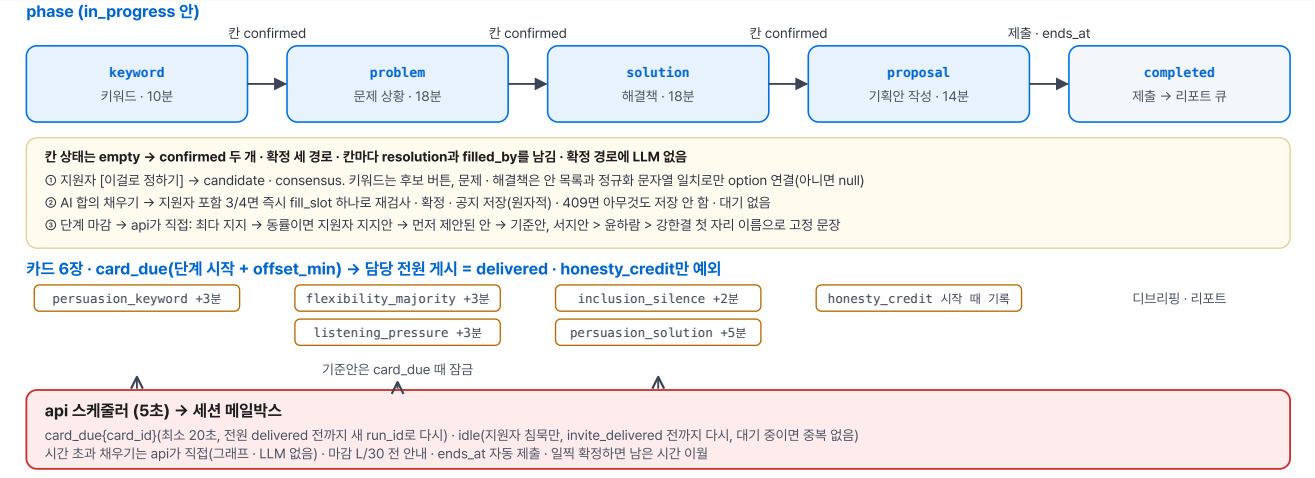


그림 3–3 단계 전환과 카드 시각. 카드 5장은 단계 시작 기준 정해진 시각에 담당 동료의 발언으로 전달되고, 정직 카드는 기획안 단계 시작 때 기록됩니다.

표 3–4 단계 중 사건과 처리

사건	감지	처리
지원자 확정	[이걸로 정하기]	확인 창 하나 뒤 칸 확정, 다음 단계로. 키워드는 후보 버튼
AI 합의 채우기	턴 매니저 fill	지원자 포함 3/4 지지면 fill_slot 한 번으로 api가 한 트랜잭션에서 재검사 · 칸 확정 · "그럼 X로 정리할게요." 저장 · generation +1. 409면 저장 없음
단계 마감	스케줄러 · 칸이 비어 있음	api가 한 트랜잭션으로 안을 고르고 우선순위 자리 이름으로 고정 문장 게시
침묵 초대	스케줄러 · 지원자 침묵	서지안이 "OO님은 어떻게 생각하세요?" 단계당 1회
카드 시각	단계 시작 + offset	담당 화자가 고정 내용을 말하고 메시지의 card_ids로 카드마다 전달 자리를 기록. 담당 전원이 말할 때까지 card_due를 다시 넣음. 발언 없는 honesty_credit만 기획안 단계 시작 때 cards 노드가 기록
세션 만료	스케줄러 · 종료 시각	현재 기획안 초안을 자동 제출하고 세션 종료

시간 규칙

단계 마감 시각은 고정이라 일찍 확정하면 남은 시간이 다음 단계로 넘어갑니다. 15분 데모는 같은 비율이고 카드 시각은 최소 20초이며, 시간 로직은 가짜 시계 단위 테스트로 검증합니다.

4. MCP 설계와 접근 경계

MCP 세 개가 손 · 눈 · 기록자를 나누고, 페르소나는 평가 기록에 닿지 않는다.

세 서버 모두 FastMCP · Streamable HTTP이고 도구는 `async def`입니다. 상태 판단은 api가 합니다. 오류는 `{ok: false, error: {code, message, retryable}}` 한 형식입니다.

표 4–1 **MCP 서버별 도구**

서버	조회	변경	경계
debate-mcp 손	get_debate_state · get_transcript · get_draft	post_message · propose_option · set_stance · fill_slot (공지 포함, 한 트랜잭션)	합의 전 fill_slot은 no_consensus
rag-mcp 눈	search_materials(청크 직접) · get_material(원문, `/internal`)	reindex_materials (관리 전용, 색인 직접 쓰기)	키워드 확정 전 not_released
assessment-mcp 기록자	get_rubric · get_session_record · get_transcript_span · get_contributions	record_observation · save_evaluation	토큰이 없으면 forbidden

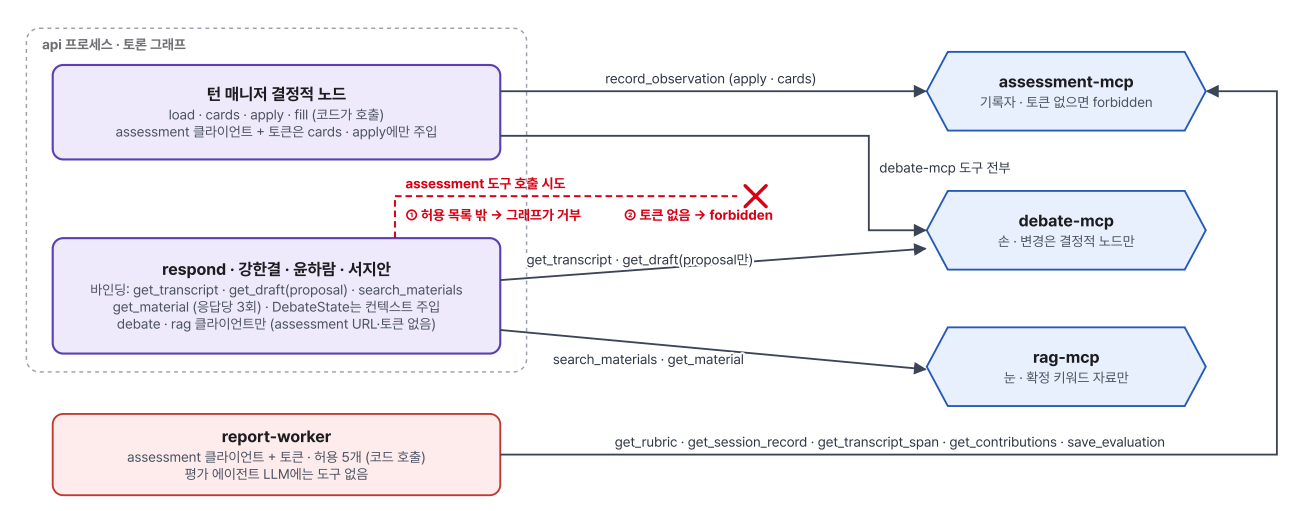


그림 4–1 MCP 접근 경계. 허용 목록과 토큰 분리, 두 겹으로 막습니다. 토큰은 cards · apply 노드에만 주입합니다.

표 4–2 **도구 허용 목록**

주체	debate-mcp	rag-mcp	assessment-mcp
턴 매니저 결정적 노드	전부	—	record_observation (cards · apply)
턴 매니저 turn (LLM)	—	—	—
페르소나 respond	get_transcript · get_draft	조회 2	**불가**
어시스턴트	—	조회 2	—
report-worker	—	—	조회 4 · save_evaluation

5. 평가 설계(BARS)

평가 에이전트는 근거가 있을 때만 수준을 내고, 최종 평가는 담당자가 한다.

세션이 끝나면 큐 작업으로 리포트 그래프가 돕니다. 요소마다 따로 호출해
다른 요소 결과를 보지 않게 하고, 초안 뒤에는 담당자 검토를 기다립니다.



그림 5–1 평가 파이프라인. interrupt 체크포인트를 먼저 저장한 뒤 draft 저장 → report_ready → ack 순서라, 승인이 오면 같은 회차 thread를 재개합니다. 새 평가 회차는 새 thread에서 collect부터 돕니다.

표 5–1 요소별 하위 차원

요소	차원	하위 차원
설득/논리력	4	근거 제시 · 반론 대응 · 경쟁 안 비교 · 논의 수렴
경청/존중	4	응답성 · 이해 확인 · 타당성 인정 · 존중하는 반대
배려/포용	4	초대하기 · 들은 의견 이어받기 · 말하기 편한 분위기 · 결정 전 목소리 확인
수용/유연성	4	다른 안 재검토 · 결정 절차 존중 · 결과 승복 · 다음 단계 기여
정직/공정	3	기여 기록의 정확성 · 토론 중 출처 존중 · 결정 과정의 사실 표현

차원마다 내는 것

수준 1~5 또는 기록 없음과 사유,
근거 참조(메시지 · 칸 · 기획안 필드), 판단 이유 1~3문장.
확신도는 기록이 있을 때 high · medium · low, 기록
없음이면 null입니다.

총점 없음 · 사람 확인

요소 수준은 차원 평균의 반올림입니다. 담당자는
차원 단위로 조정하고 메모를 남기며, 합격 · 순위는
만들지 않습니다.

6. 품질 관리와 하네스

안전장치는 코드에 걸고, 검증은 층마다 계획으로 정했다.

프롬프트에 맡기면 흔들리는 규칙은 결정적 코드로 강제합니다. 스파이크 외 검증은 계획이며 통합 뒤 기록합니다.

표 6–1 **하네스 8요소**

요소	적용
Instructions	공통 규칙 · 페르소나별 프롬프트 · 평가 프롬프트를 채용 건에 복사해 고정
Tools	노드별 허용 목록, 응답당 도구 3회, 검색 상위 3, 페르소나의 assessment 차단
Context	페르소나에게 척도 · 관찰 · 다른 자리 성향 · 열리지 않은 자료를 넣지 않음
State · Memory	PostgresSaver 체크포인트(`debate:` · `assistant:` · `report:{session_id}:{eval_round}`), 자리별 기억
Agent Loop	실행당 화자 2명, 같은 자리 연속 3회 금지 (카드 · 지명 응답 제외), 침묵 초대 단계당 1회
Guardrails	guard · stance_check, 합의 전 칸 채우기 409, 근거 없는 수준 거부
Recovery	발언 실패 생략, 리포트 최초 포함 3회(추가 재시도 2회) 뒤 DLQ, 멱등 키로 재실행
Observability	LangSmith trace, 실행별 결정 · 사용량 기록, 비용 cost_usd 관측(목표 $0.5) · debate_cost_usd 상한 $2

표 6–2 **검증 계획**

층	확인하는 것	상태
단위	턴 규칙 · 카드 트리거 · guard · 평가 출력 검증 · 시간 로직(가짜 시계)	계획
연결	메시지 → 분류 → 그래프 → MCP → WS 최소 경로, 자료 차단, assessment 거부	계획
e2e	15분 세션 대본(전 요소 · 전부 시간 초과 · 정직 대조), 큐 DLQ · 타임아웃 장애 주입	계획
의도 분류	20문장 intent 정확도	스파이크 측정
BARS 픽스처	사람 평가와의 수준 차이	계획

표 6–3 **사전 검증(스파이크) 결과 · gpt-4o-mini**

항목	값	비고
의도 분류 지연	`1.0 / 1.2`초	p50 / p95, 63회
페르소나 발언 지연	`1.2 / 1.4`초	p50 / p95, 21회
턴 LLM 지연	`1.2 / 1.5`초	p50 / p95, 11회
60분 세션 비용 추정	`$0.08~0.11`	지원자 40~80메시지 가정, 목표 $0.5 안
의도 분류 정확도	`0.85`	키워드 단계 20문장 × 3회, 기준선 프롬프트

7.1 지원자 화면

토론, 결정, 기획안 작성이 한 화면에서 이어진다.

가운데 토론방과 우측 탭(결정 사항 · 자료 · AI 어시스턴트 · 기획안), 상단 단계 진행바와 남은 시간으로 구성합니다.

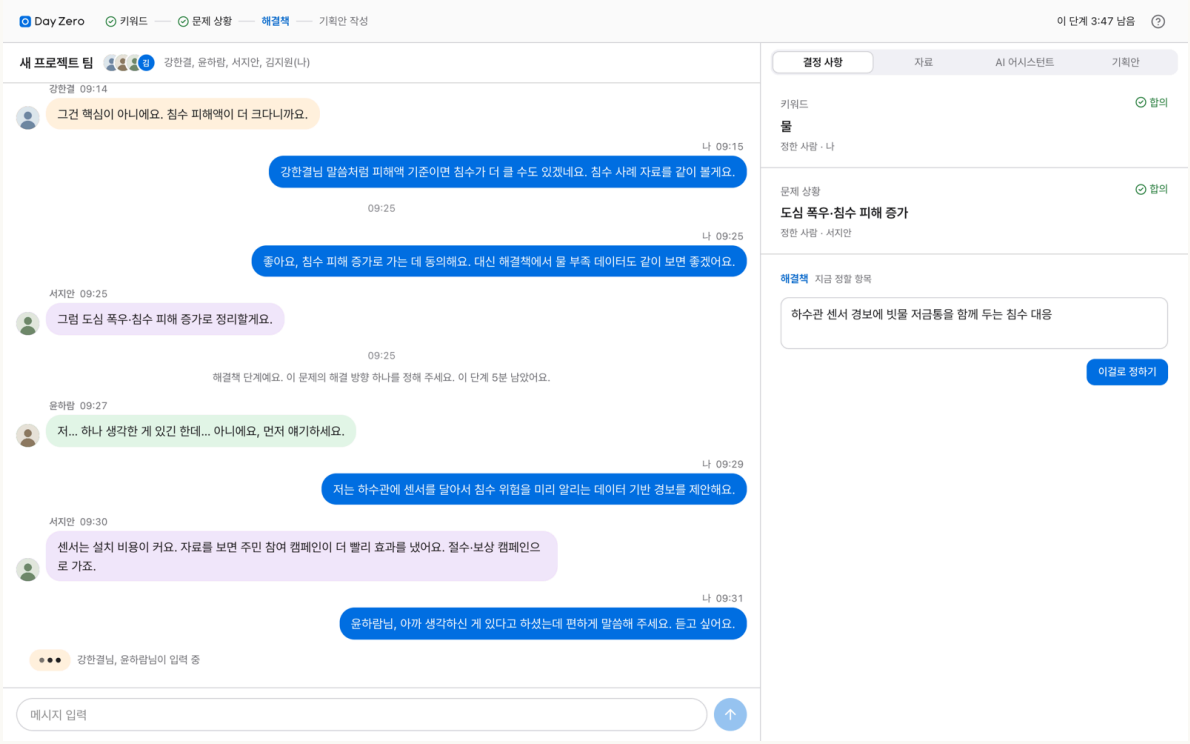


그림 7–1 지원자 토론방. 사람별 말풍선 색과 이름, 가운데 회색 시스템 안내, 입력 중 표시 (목업, 예시 데이터)

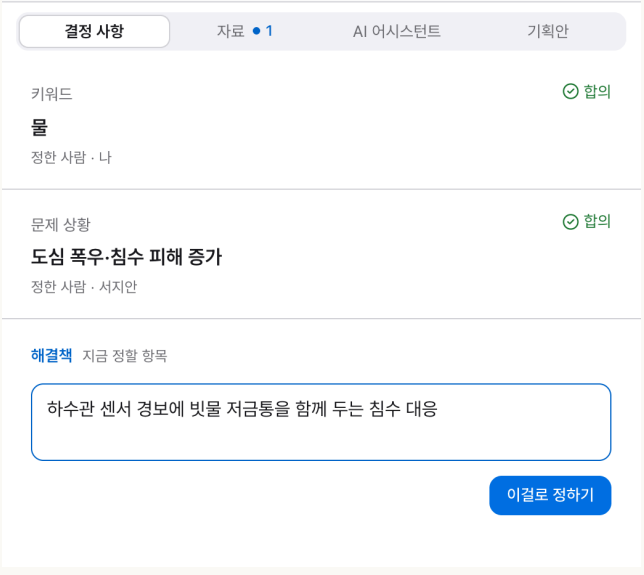


그림 7–2 결정 사항 패널. 정한 결과와 정한 사람, 현재 항목의 [이걸로 정하기] (목업, 예시 데이터)



그림 7–3 기획안. 6칸 폼 중 해결책 · 근거 · 기대효과 · 아이디어 기여와 자동 저장, 제출 (목업, 예시 데이터)

7.2 디브리핑과 관리자 리포트

지원자는 설계된 장면을 설명받고, 담당자는 근거를 보며 차원 단위로 조정한다.



그림 7–4 디브리핑. 같은 장면 안내와 이번 세션의 장면 (목업, 예시 데이터)

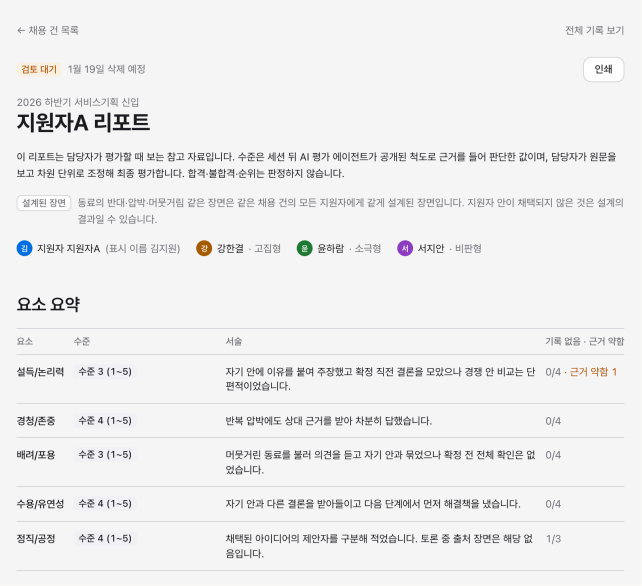


그림 7–5 관리자 리포트. 설계된 장면 표시와 요소별 수준 요약, 총점 없음 (목업, 예시 데이터)

표 7–1 화면별 주요 기능

화면	주요 기능
지원자 토론방	사람별 말풍선 색과 이름 · 아바타, 가운데 회색 시스템 안내, "OO님이 입력 중" 표시, 단계 진행바와 남은 시간
결정 사항 패널	정한 결과 줄과 합의 · 시간 초과 표시, 정한 사람. 현재 항목에만 입력, 키워드는 후보 버튼, 정하기는 확인 창 하나
기획안	키워드 · 문제 상황 · 해결책 · 근거 · 기대효과 · 아이디어 기여 6칸, 자동 저장 시각 표시, 제출
디브리핑	"같은 채용 건의 모든 지원자가 같은 장면을 겪었다"로 시작, 이번 세션의 장면, 보는 요소, 내 발언 돌아보기, 이의 제기 경로, 종료 설문. 척도 세부와 수준은 공개하지 않음
관리자 리포트	요소 수준 요약(총점 없음), 차원별 확신도, 근거 앞뒤 맥락과 "기록에서 보기", 차원 단위 조정(메모 필수), 인쇄

8. 한계와 개선 방향

MVP 실행을 확인했고, 평가 신뢰도와 편향 검증은 별도로 필요하다.

현재의 한계와 대응을 정리하고, MVP 이후 고려할 개선 방향을 남깁니다.

표 8–1 한계와 대응

한계	영향	대응
목업 기준 캡처	7장 화면은 목업 데이터로 동작하는 UI 캡처	실 스택 캡처는 통합 후 교체
척도 · 시나리오 초안	차원 앵커 · 카드 시각 수치가 검토 전	검토 뒤 카탈로그 버전으로 고정
평가 일치도 미측정	LLM 판단이 같은 대화에도 흔들릴 수 있음	사람 2인과 차이 분포, 3회 재평가 변동 폭 측정
api 단일 프로세스	메일박스 · 송신 큐 · 스케줄러가 메모리에 있음	AgentRunner 경계에서 분리 가능
채팅 숙련도 편향	타자 속도 · 내향성이 불리할 수 있음	발언 수로 수준을 올리지 않음, 상관 점검
규제 해석	채용은 고영향 AI 영역 해당 여부가 미확정	사람이 최종 결정하는 구조, 법률 검토

표 8–2 MVP 이후

#	항목
1	지원자가 입력 중이면 페르소나 생성 전에 확인해 버려지는 생성을 줄인다
2	한 메시지에 담긴 여러 의도를 분류한다
3	대상 라벨이 없는 분류 결과는 confidence를 low로 강제하는 후처리를 둔다
4	턴 LLM의 화자 쏠림을 보정한다
5	서비스 간 websockets 버전을 통일한다